



RAPPORT DE STAGE DE FIN DE MASTER 1

Candidat: Gabriel Faraut, M1 IAFA
Tuteurs: Julien Pinquier enseignant-chercheur à IRIT, Toulouse
Mathieu Balaguer, orthophoniste et chercheur à IRIT, Toulouse
IRIT – août 2024

ADAPTATIONS DU SYSTÈME DE RECONNAISSANCE AUTOMATIQUE DE PAROLE EN CONTEXTE PATHOLOGIQUE

Table des matières

A - Introduction....3
a) Présentation de l'IRIT....3
b) Infrastructures et matériel....3
c) Modalités du stage....3
B - Problématique....4
a) Contexte scientifique....4
b) Problématique et objectif du stage....4
C - Construction du corpus de données....4
a) Corpus existants....4
b) Extraction automatisée des données des corpus....5
c) Construction du corpus d'apprentissage....5
d) Construction du corpus de test....5
D - État de l'Art....7
a) Modèles de diarization audio....7
b) Modèles de transcription audio....7
E - Amélioration des modèles existants....8
a) Création de fonctions «user-friendly»....8
b) Données d'entraînement....9
c) Fine-tuning de Speechbrain....9
d) Autres tentatives....9
F - Résultats....10
a) Mesure et comparaison de la qualité des transcriptions....10
b) Mesures comparatives des différents modèles sur le corpus SPEECOMCO et observations....10
c) Test statistique....11
G - Conclusion....12
H - Bibliographie....12
I - Annexe....14
a) Structure détaillée de Speechbrain wav2vec2....14
b) Mesures comparatives des différents modèles sur le corpus SPEECOMCO....16
c) Données statistiques....18
d) Tests statistiques....20

A - Introduction

a) Présentation de l'IRIT

L'Institut de Recherche en Informatique de Toulouse ou IRIT est un laboratoire implanté sur le campus universitaire Toulouse 3 - Paul Sabatier. En août 2024, 507 personnes y travaillent (dont 226 chercheurs et enseignants-chercheurs et 257 doctorants et post-doctorants/contractuels/ATER). Le laboratoire est structuré en équipes, dont SAMoVA (Structuration, Analyse et Modélisation de documents Vidéo et Audio) faisant partie du département Signaux et Images. Cette équipe est constituée en juillet 2024 de 10 membres permanents (enseignants et chercheurs), 17 membres non-permanents (chercheurs associés, doctorants ou stagiaires) et 1 membre externe. L'équipe SAMoVA est spécialisée dans le traitement de problématiques de traitement automatique de données audiovisuelles. L'une des thématiques principales de cette équipe est le traitement automatique de la parole pathologique.

b) Infrastructures et matériel

OSIRIM est le serveur interne de l'IRIT.

Il y existe deux types de nœuds donnant accès aux GPU : 7 serveurs Dell T630 bi pro Intel Xeon 2640 de 10 cœurs à 2,4 GHz, 192 Go de RAM et 4 cartes Nvidia GTX 1080Ti, et 1 serveur Dell R740 bi pro Intel Xeon 2630 de 20 cœurs à 2,1 GHz, 192 Go de RAM et 3 cartes Nvidia RTX 6000,

Deux autres types de nœuds ne donnent accès qu'aux CPU : 12 serveurs Dell C6420 bi pro Intel Xeon Gold 6136 de 12 cœurs à 3 GHz et 192 Go de RAM, et 4 serveurs Dell C6525 bi pro AMD EPYC Rome 7402 de 24 cœurs à 2,8 GHz et 512 Go de RAM.

Tout membre permanent ou temporaire de l'IRIT peut réserver un de ces nœuds en créant un serveur temporaire, pour une durée maximale de 19 heures, ce qui permet de lancer de longs processus.

c) Modalités du stage

Le stage s'est déroulé sur 13 semaines, du 29 avril au 26 juillet 2024, du lundi au vendredi à raison de 7 heures par jour.

B - Problématique

a) Contexte scientifique

L'objectif général est d'étudier l'état d'esprit et la dynamique des patients ayant subi un traitement (souvent chirurgical) de la sphère ORL suite à un cancer, afin de faciliter l'accompagnement des patients par leurs orthophonistes et les médecins en charge du suivi des patients. Une telle tâche d'analyse émotionnelle de la parole est d'ores et déjà traitée avec des outils automatiques basés sur une architecture d'intelligence artificielle de type BERT [8] (spécialisée dans la classification de données de type texte). Or, pour analyser la parole, il faut préalablement la transcrire en texte. Whisper [2] (OpenAI) et Speechbrain [7] (open-source) sont les principaux outils actuellement employés pour la transcription de parole en texte. Le problème est alors que les patients atteints de cancers de la sphère ORL et éventuellement opérés souffrent le plus souvent de troubles de prononciation d'ordres et de degrés divers, compliquant significativement leur intelligibilité et leur compréhensibilité et de surcroît brouillant la transcription automatique.

b) Problématique et objectif du stage

Pour mener à bien l'analyse émotionnelle de la parole des patients, il est nécessaire d'améliorer sa transcription automatique par les modèles existants. L'une des possibilités pour améliorer les performances d'un modèle de reconnaissance ou de génération automatique est de lui appliquer un "fine-tuning", c'est-à-dire de compléter son entraînement avec un jeu de données supplémentaire.

L'objectif du stage est alors d'améliorer les performances des modèles de transcription existants (modèles de Speechbrain francophones ou versions fine-tunables de Whisper) en les entraînant sur des enregistrements de parole pathologique issus du projet Parolothèque de l'IRIT.

C - Construction du corpus de données

a) Corpus existants

SpeeCOmco, C2SI, RUGBI et DAPADAF-E sont les quatre corpus du projet Parolothèque et contiennent des enregistrements de patients du CHU de Toulouse atteints d'un cancer de la sphère ORL, la plupart ayant subi des opérations chirurgicales en conséquence. Chaque patient effectue une série de tests orthophoniques. Les corpus RUGBI et C2SI contiennent des lectures de texte (les premières phrases de La Chèvre de Monsieur Seguin d'Alphonse Daudet), de phrases et de pseudo-mots (mots n'existant pas en français, par exemple « crerquin ») par de nombreux patients. Le corpus DAPADAF-E contient uniquement des enregistrements de pseudo-mots. Le corpus SPEECOMCO (2020) présente les tests de trente patients sur la lecture de phrases, de texte, de pseudo-mots, mais aussi sur la parole spontanée, par le biais d'un entretien de dix à vingt minutes avec l'orthophoniste, dans l'objectif d'évaluer quantitativement la sévérité de leur trouble selon un barème de 0 (trouble sévère) à 10 (absence de trouble perceptible) livré par six juges professionnels (médecins et orthophonistes). Les entretiens de 27 de ces sujets ont fait l'objet d'une transcription manuelle minutée à la milliseconde près (à la seconde près pour les patients 20 et 21).

b) Extraction automatisée des données des corpus

Les répertoires de chacun des quatre corpus sont stockés dans le répertoire Parolothèque (du nom de l'un des projets de l'équipe SAMoVA) du serveur OSIRIM. Les noms des fichiers audio suivent une nomenclature propre à chaque corpus ; on y trouve donc le numéro du patient, l'indicatif du test effectué et, éventuellement, le numéro de l'essai pour un test donné. Ainsi, il est possible de trier les fichiers audio d'un même corpus selon les éléments variables de leurs noms. J'ai donc écrit une fonction (« cratedigger ») automatisant la création d'un dictionnaire de dictionnaires de listes, pour trier l'ensemble des fichiers d'un répertoire et de ses sous-répertoires (avec la possibilité d'indiquer un suffixe de fichiers à cibler) selon deux éléments variables de la nomenclature (en l'occurrence, le numéro de patient et l'indicatif du test). Le problème est que les fichiers du corpus RUGBI étant sujets à des erreurs de nommage, il faut capter les exceptions autant que possible. Une solution est de modifier directement les noms des fichiers concernés sur le serveur pour les faire correspondre à la nomenclature du corpus RUGBI. Cette solution est dangereuse en raison du risque d'écrasement de fichier par renommage, et de l'impossibilité d'annuler directement une telle erreur. J'ai donc implémenté dans la fonction « cratedigger » la possibilité de capturer automatiquement les erreurs de nommage sur la base des séquences régulières de caractères de la nomenclature.

Comme seul le corpus SpeeCOmco contient la parole spontanée des patients, ce sera l'unique corpus exploité pour le présent stage.

c) Construction du corpus d'apprentissage

Le travail de transcription et de minutage manuels des entretiens est certes fastidieux mais se révèle indispensable pour la construction du corpus. En effet, l'inclusion des entretiens dans le corpus pose deux problèmes majeurs. D'une part, les différents modèles de Speechbrain ne sont entraînés que sur des extraits d'au plus dix secondes, ce qui limite drastiquement son efficacité et son intérêt pour la transcription de longs fichiers audio, au contraire de Whisper qui est entraîné sur des fichiers audio plus éclectiques (car provenant de vidéos YouTube) et de longueur variable, et qui prend mieux en charge le contexte. D'autre part, dans les fichiers des entretiens, la voix de l'orthophoniste, quoique moins forte que celle du patient, reste audible et des tests préliminaires ont montré que les modèles captent indifféremment les paroles de l'orthophoniste et du patient.

Pour construire notre jeu de données, il faut segmenter les fichiers audio des entretiens selon le minutage de chaque fichier de transcription d'entretien, où à chaque mot est assigné un timecode de début, un timecode de fin et un numéro d'interlocuteur (0 ou 1). Ensuite, on regroupe les mots consécutifs en fonction de la proximité de leurs timecodes, de manière à ce que la durée cumulée soit comprise dans une fourchette de durée déterminée (ici, entre 5 et 30 secondes). Nous obtenons alors des groupes de mots avec de nouveaux timecodes pour découper et labelliser les fichiers audio.

d) Construction du corpus de test

Il serait tentant d'utiliser également le minutage manuel existant pour découper les fichiers audio. Or, le découpage automatique des fichiers audio sera nécessaire afin d'effacer plus efficacement la voix de l'orthophoniste qui fausserait l'évaluation de la transcription automatique. Un tel découpage automatique

est faisable avec la bibliothèque Pyannote [1], dont la finalité première est, pour un fichier audio donné, d'identifier chaque interlocuteur par un numéro et de délimiter les interventions (« qui parle quand »). Cependant, l'utilisation de Pyannote pose encore plusieurs problèmes. Du fait du faible volume de la voix de l'interlocuteur, il peut arriver que Pyannote soit pris d'hallucination et identifie des interlocuteurs surnuméraires, qui n'existent pas. De plus, malgré le fait que l'orthophoniste est le premier à parler lors des entretiens, seules certaines de ses interventions sont captées, ce qui fait que l'ordre de numérotation des interlocuteurs (orthophoniste ou patient) n'est pas constant.

Il faut donc trouver un moyen de sectionner les fichiers audio des entretiens de manière à, d'une part, l'isoler le mieux possible de la parole de l'orthophoniste et, d'autre part, de garder une régularité dans la durée des extraits de parole. Pour cela, j'ai procédé en plusieurs étapes. Pour chaque entretien:

- On balise chaque prise de parole par un minutage et un numéro d'interlocuteur avec la librairie Pyannote ;

- On identifie quel numéro d'identificateur correspond à la parole du patient – c'est la seule étape non automatique du processus – ;

- On efface – c'est-à-dire on remplace par le signal nul – les extraits de l'audio où la voix du patient n'est pas présente, avec un padding (ici 0,5 seconde) pour éviter d'une part une coupure trop brutale qui nuierait à la transcription automatique, d'autre part la présence de parole en tout début ou en toute fin de fichier qui peut perturber Speechbrain ;

- On regroupe les extraits de la voix du patient selon leur minutage, comme nous l'avons fait pour les minutages manuels, on obtient alors un nouveau minutage ;

- On procède au découpage des fichiers audio (préalablement nettoyés de la voix de l'orthophoniste comme mentionné plus haut) selon ce nouveau minutage.

D'autre part, nous allons également tester les différents modèles sur des extraits de parole contrainte, précisément les premières phrases du roman La Chèvre de Monsieur Seguin, un autre des six tests orthophoniques effectués par chacun des patients ayant prêté leur voix au projet SpeeCOmco.

D - État de l'Art

Après l'extraction des données du corpus SpeeCOmco, la deuxième étape de ce stage fut d'explorer les différents modèles de diarization audio et de transcription de signal audio en texte.

a) Modèles de diarization audio

Pyannote [5] est un outil open-source et protégé par la licence MIT, destiné à la diarization, c'est-à-dire l'annotation de fichiers audio contenant de la parole, en attribuant à chaque extrait de parole un minutage et un numéro d'interlocuteur. Ce modèle obtient un score de DER (Diarization Errore Rate) de 12,5 % sur le corpus VoxConverse et de 43,2 % sur le corpus NFI-FRITS selon la thèse de A. Mul [5]. Sur le corpus VoxConverse, l'étude fait état d'une corrélation entre le DER et le nombre d'interlocuteurs, de l'ordre de 0,4% d'erreur en plus par interlocuteur supplémentaire. C'est le modèle qui a été utilisé dans le cadre de ce stage.

NeMo [5] est un autre outil de diarization, quant à lui propriétaire, supporté par Nvidia. De même, ce modèle obtient un score de DER de 11,8 % sur le corpus VoxConverse et de 18,4 % sur le corpus NFI-FRITS selon la thèse de A. Mul [5].

b) Modèles de transcription audio

Les deux principales séries de modèles de transcription sont Whisper, modèle propriétaire créé par la société OpenAI, et Speechbrain, recueil de modèles en open-source, sous la licence Apache 2.0,

Whisper [2] est un modèle multilingue décliné en plusieurs versions distinguées par la taille du dataset (Tiny, Base, Small, Medium, Large). Il est possible de fixer la langue de transcription en paramètres. L'utilisation de Whisper pose plusieurs problèmes : des hallucinations (vraisemblablement dues au dataset d'entraînement de Whisper, essentiellement constitué de vidéos YouTube sous-titrées) et des dérapages linguistiques (que ne résoud pas tout à fait le paramétrage de la langue) et une faible marge de manœuvre en paramètres. En revanche, Whisper Large a été décliné en deux versions v2 et v3, qui sont ouvertes au fine-tuning.

Il existe à ce jour (août 2024) 120 modèles de **Speechbrain** [7], chacun défini avec une architecture (CNN, CRDNN, Hifigan, transformer, sepformer, etc) et spécialisé en une seule langue. Parmi ces modèles, six sont disponibles en version francophone : CRDNN, wav2vec2, transformer, transducer, et des implémentations de Whisper Medium et Large. Lors de son utilisation, le transformer a provoqué un bug sans que nous puissions y remédier. Les implémentations de Whisper dans Speechbrain n'apportent aucune valeur ajoutée par rapport aux Whisper Medium et Large originaux et qui plus est arrêtent la transcription au bout de dix secondes. J'ai donc mené des tests de transcription préliminaires pour discriminer les modèles CRDNN, wav2vec2 et transducer. Le modèle wav2vec2 s'est révélé être le meilleur des trois.

La particularité du modèle **wav2vec2** de Speechbrain est, comme son acronyme le suggère, un premier algorithme encodant le signal sonore en vecteurs, décomposé en trois parties. La première extrait les caractéristiques du signal ; elle est composée de sept couches de convolution de 512 canaux sur 1 dimension, chacune suivie d'une fonction d'activation GELU (Gaussian Error Linear Unit) [4]. La deuxième, pour la projection des caractéristiques, est une fonction linéaire. La troisième effectue l'encodage proprement dit avec vingt-quatre couches de passe forward chacune précédées d'une matrice

d'attention afin d'améliorer la vitesse de calcul. Dans les trois parties de cet algorithme wav2vec2 viennent s'intercaler des couches de normalisation et de « dropout » (remplacement aléatoire de 10 % des valeurs des vecteurs par la valeur 0).

De par sa continuité sur tout son domaine de définition ($\mathbb{R}$) et son absence de cassure à x = 0, contrairement à la fonction ReLU (linéaire pour x > 0, nulle sinon), la fonction GELU prévient le problème de chute exponentielle de gradient lors de sa propagation aux couches de neurones, qui laisse des groupes de neurones inactifs, entravant voire bloquant l'apprentissage du modèle.

$$GELU(x) = 0{,}5\,x\left(1+\tanh\left(\sqrt{\frac{2}{x}}\left(x+0{,}044715\,x^{3}\right)\right)\right)$$

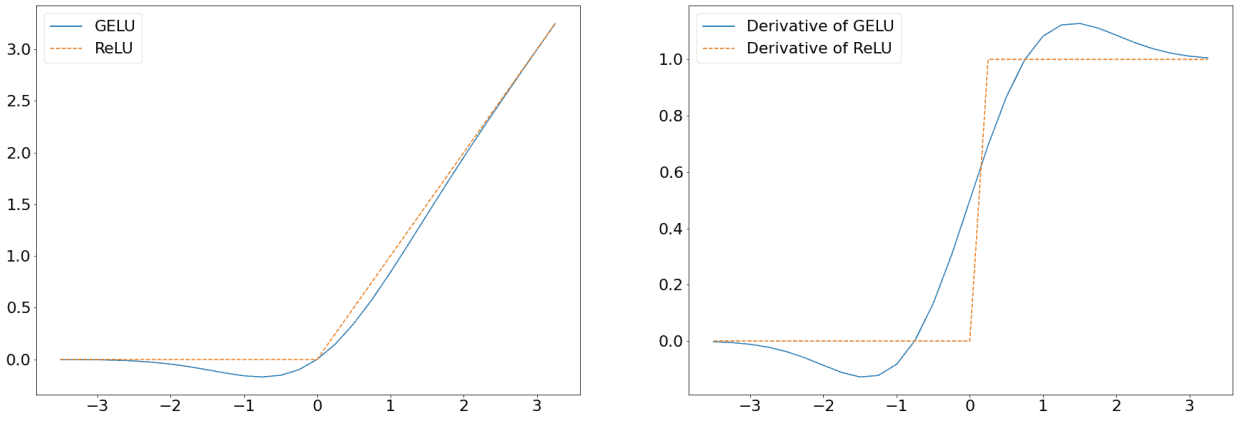


Figure 1: Trace des fonctions ReLU (en pointillés) et GELU, puis de leurs dérivées respectives (source: baeldung.com)

Nous nous sommes également penchés sur le modèle **SeemLessM4T** de Meta, sans pouvoir le tester à cause d'un bug à l'importation sur OSIRIM que nous n'avons pas pu résoudre durant la période de stage.

E - Amélioration des modèles existants

a) Création de fonctions «user-friendly»

Afin d'améliorer la prise en main de Pyannote, nous avons écrit une fonction « pyanee » permettant d'effectuer toutes les étapes du processus de diarization en une seule fois, ainsi qu'une fonction complémentaire "vad_to_audio" découpant le fichier audio à partir d'un minutage défini automatiquement avec Pyannote. Ces deux fonctions couvrent la quasi-totalité du processus d'annotation et de découpage décrit en partie C - sous-partie c (à l'exception donc du choix de l'interlocuteur en vue du découpage). La liste des minutage et des annotations est transmise d'étape en étape via des fichiers texte.

Nous avons également créé les fonctions "whispee" et "speechee", pour respectivement Whisper et Speechbrain, dans la même optique d'en améliorer la maniabilité. La création de "speechee" a essentiellement été motivée par le besoin de lancer en une fois des transcriptions successives sur des extraits d'entretiens – spécifiés sous la forme soit d'une liste de listes (les signaux bruts), soit d'une liste de chaînes de caractères (les noms et chemins de répertoire des fichiers) – découpés avec Pyannote –

découpage lui-même motivé par les limites de Speechbrain.

b) Données d'entraînement

Comme dit plus haut, seuls les entretiens du corpus SpeeCOmco seront utilisés dans le corpus d'apprentissage.

Pour éviter de trop fortement biaiser le modèle à l'apprentissage, seuls les entretiens des patients ayant un score de sévérité strictement supérieur à 6/10 (donc dont le trouble de parole est considéré comme faible ou médéré) sont sélectionnés pour le jeu de données d'entraînement – des extraits d'entretiens de 16 patients totalisant 4 à 5 heures. Pour tester le modèle sur l'entretien d'un patient parmi les moins atteints (score > 6), on procède selon la méthode dite "leave-one-out", c'est-à-dire on retire l'entretien en question du dataset d'entraînement le temps de tester le modèle dessus, et ainsi de suite pour les entretiens de tous les patients peu atteints. Pour les patients dont le trouble de parole est plus sévère (score ≤ 6), on procède de manière conventionnelle, c'est-à-dire on entraîne le modèle sur les entretiens de tous les patients peu atteints, et on le teste sur tous les autres entretiens.

c) Fine-tuning de Speechbrain

Nous avons mené plusieurs essais de fine-tuning de Speechbrain wav2vec2 en faisant varier le paramétrage : le nombre d'epochs (cycles d'apprentissage), la taille des batchs (unités de traitement par lot, se succédant au cours d'un cycle) ou le facteur d'accumulation de gradient (facteur indiquant tous les combien de batchs met-on à jour les paramètres – permet d'économiser de la mémoire vive lors du processus). Pour des raisons de limites en puissance de calcul, nous avons initialement bridé la taille des batches à 8 et fixé le facteur d'accumulation de gradient à 4. Nous avons fait varier le nombre d'epochs de 4 à 20, et éventuellement bridé l'accumulation de gradient à 2 et augmenté la taille des batchs à 12.

d) Autres tentatives

Il est possible de fine-tuner la version Large v3 de Whisper. Hélas, « accelerate », l'une des bibliothèques nécessaires à cette opération, entre en conflit avec « transformers_engine », qui non seulement fait doublon avec « transformers » mais est préinstallé sur le serveur OSIRIM et disponible en lecture seule, et donc impossible à désinstaller pour qui n'est pas administrateur. En l'état des choses, ce problème compromet le fine-tuning de Whisper Large v3 sur OSIRIM.

F - Résultats

a) Mesure et comparaison de la qualité des transcriptions

Le taux d'erreur de mots (ou Word Error Rate, WER) est la mesure la plus fréquemment utilisée pour quantifier la proximité entre deux textes, et en l'occurrence pour évaluer la performance d'un modèle de transcription d'audio par rapport à un texte référence. La formule du WER est WER = (S + D + I) / N = (S + D + I) / (S + D + C) tels que S est le nombre de mots substitués, D le nombre de mots supprimés, I le nombre de mots indûment insérés dans le texte hypothèse, C le nombre de mots identiques entre la référence et le texte hypothèse, et N le nombre total de mots du texte référence. Le taux d'erreur de caractères (ou Character Error Rate, CER) est simplement une application de la formule du WER à l'échelle des caractères et permet une meilleure qualité d'évaluation vis-à-vis du WER qui valide un mot entier à la moindre erreur de caractère.

Je me suis également penché sur la distance de Damerau-Levenshtein qui donne le nombre d'opérations (insertions, suppressions, substitutions) nécessaires pour passer d'une chaîne de caractères à une autre. Cette métrique a été initialement conçue pour quantifier les fautes d'orthographe entre un mot-référence et un mot-hypothèse et s'est révélée inadaptée à l'échelle d'un texte complet. J'ai donc décidé, pour mon étude comparative des modèles existants et des différentes versions de mes modèles fine-tunés, d'utiliser successivement le WER et le CER.

b) Mesures comparatives des différents modèles sur le corpus SPEECOMCO et observations

Pour Whisper Large, Speechbrain wav2vec2 et six versions finetunées successives de wav2vec2, nous avons évalué la transcription de l'entretien et de la lecture de texte de chacun des 27 patients du corpus SpeeCOmco avec le WER et le CER. Nous avons également calculé la moyenne et la médiane des WER et des CER pour chacun des huit modèles, sur toutes les transcriptions (cf. Tableau 1), puis sur celles des 16 patients les moins atteints et celles des 11 patients les plus atteints (cf. Annexe). Nous avons complété ces calculs avec les premier et troisième quartiles sur les données globales.

Tableau 1: Moyennes et médianes des WER des différents modèles

Modèle	Moyenne WER parole spontanée	Médiane WER parole spontanée	Moyenne WER parole contrainte	Médiane WER parole contrainte
Whisper Large	0,684	**0,673**	**0,388**	**0,235**
Speechbrain wav2vec2	**0,668**	0,71	0,544	0,574
Sb w2v PSI6 b8e4g4	0,717	0,763	0,583	0,676
Sb w2v PSI6 b8e8g4	0,701	0,751	0,567	0,603
Sb w2v PSI6 b8e12g4	0,687	0,737	0,567	0,588
Sb w2v PSI6 b8e16g2	0,682	0,728	0,561	0,588
Sb w2v PSI6 b8e20g2	0,681	0,726	0,558	0,588
Sb w2v PSI6 b12e20g2	0,679	0,722	0,560	0,588

Les calculs de moyennes et de médianes montrent, *de visu*, une amélioration graduelle des performances

des modèles fine-tunés à mesure que l'on augmente le nombre d'epochs à l'entraînement (cf. Annexe). Cependant, aucune de ces versions fine-tunées ne minore le WER ou le CER sur la parole contrainte ou spontanée (donc ne montre une amélioration des performances). Nous observons globalement que les meilleurs scores sont obtenus avec Whisper Large sur les transcriptions de parole contrainte ou peu altérée, et avec Speechbrain wav2vec2 sur la parole spontanée ou altérée.

c) Test statistique

Le test statistique de Wilcoxon-Mann-Whitney [3] permet de quantifier la proximité entre les distributions de deux groupes de données X et Y (de taille non forcément égales), ou plus précisément la probabilité de l'hypothèse H_0: $P(X > Y) = P(Y > X)$, autrement dit « la probabilité qu'une observation de la population X soit supérieure à une observation de la population Y est égale à la probabilité qu'une observation de la population Y soit supérieure à une observation de la population X ».

La méthode mannwhitneyu de la bibliothèque Scipy fournit, pour deux populations X et Y, la valeur U du test de Wilcoxon-Mann-Whitney, et la probabilité p de l'hypothèse H_0 pour deux populations X et Y. On considère qu'on peut rejeter l'hypothèse nulle i.e. que les distributions de ces populations sont significativement différentes pour une probabilité p inférieure à 0,05.

Aucune des évaluations menées avec ce test statistique ne révèle une quelconque amélioration significative des performances des versions fine-tunées de Speechbrain wav2vec2 entre elles ou par rapport au wav2vec2 original ou encore Whisper Large ($p>0,05$), ce qui confirme les impressions données par les calculs de moyennes et de médianes. Les évaluations montrent même que Whisper est significativement plus performant que Speechbrain wav2vec2 et toutes ses versions fine-tunées sur le WER de la transcription de la lecture de texte. Nous avons retrouvé un tel écart de performance entre Whisper et certains des modèles fine-tunés (surtout ceux entraînés à 4 et 8 epochs) sur le CER de la transcription de la parole spontanée des patients.

G - Conclusion

Les résultats du fine-tuning de Speechbrain durant ce stage ne sont pas concluants. Les performances des versions fine-tunées de Speechbrain demeurent inférieures à celles de la version non fine-tunée, et à plus forte raison de celles de Whisper. Les principales raisons en sont, selon nous, une trop faible quantité et une trop grande hétérogénéité des données d'entraînement, découlant de la grande diversité des troubles d'articulation de la parole couverts par le corpus SpeeCOmco, ce qui empêche le modèle d'apprendre efficacement. Qui plus est, la législation restrictive quant au stockage et à l'accès extérieur aux données des hôpitaux limite leur exploitation par les équipes de recherche. Nous voyons donc notre stage comme une piste de travail plutôt qu'un projet abouti.

Les pistes d'amélioration que l'on peut envisager serait la collecte de davantage d'enregistrements annotés de voix pathologique dans les archives hospitalières pour enrichir le jeu de données (temporairement impossible du fait de la législation des données hospitalières), et l'essai, quand cela sera possible, du fine-tuning de Whisper.

Ce stage nous aura néanmoins été formateur, tant au sujet de la pratique de l'intelligence artificielle que de la gestion du travail individuel en laboratoire ou de l'entraide entre travailleurs. Un séminaire interne à l'équipe SAMoVA les 12 et 13 juin ainsi que la série de conférences JEP - TALN (traitement automatique de la parole et recherche d'information textuelle) à l'université Jean Jaurès de Toulouse du 8 au 12 juillet nous ont renseigné sur l'avancement des recherches autour de la transcription de la parole et de l'analyse automatique de texte.

Je souhaite remercier particulièrement mes encadrants MM. Pinquier et Balaguer, mes collègues stagiaires Satya Capblancq, Néo De Sa Moreira et Lamya Belkadi, ainsi que tous les autres chercheurs et étudiants que j'ai eu le bonheur de côtoyer durant mon stage.

H - Bibliographie

1a – H. Bredin, H., Yin, R., Coria, J. M., Gelly, G., Korshunov, P., Lavechin, M., Fustes, D., Titeux, H., Bouaziz, W., & Gill, M. (2019b). pyannote.audio : neural building blocks for speaker diarization. arXiv (Cornell University). https://doi.org/10,48550/arxiv.1911.01255

1b – H. Bredin (2023). pyannote.audio 2.1 speaker diarization pipeline: principle, benchmark, and recipe. 24th INTERSPEECH Conference (INTERSPEECH 2023), Dublin, Ireland. pp.1983-1987, 10,21437/Interspeech.2023-105

2 – J. Batista (2024). Learn OpenAI Whisper – https://katalog.ub.uni-heidelberg.de/cgi-bin/titel.cgi?katkey=69228121

3 – H.B. Mann, D.R. Whitney (1947). On a Test of Whether one of Two Random Variables is Stochastically Larger than the Other – https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-18/issue-1/On-a-Test-of-Whether-one-of-Two-Random-Variables/10.1214/aoms/1177730491,full

4 – Minhyeok Lee (2023). Mathematical Analysis and Performance Evaluation of the GELU Activation Function in Deep Learning. https://onlinelibrary.wiley.com/doi/full/10,1155/2023/4229924

5 – Anouk Mul (2023). Enhancing Dutch Audio Transcription through Integration of Speaker Diarization into the Automatic Speech Recognition model Whisper. https://studenttheses.uu.nl/bitstream/handle/20.500.12932/44643/1429264_MUL_Thesis_FINAL_VERSION.pdf?sequence=1&isAllowed=y

6 – Fred J. Damerau (1964). A technique for computer detection and correction of spelling errors – https://dl.acm.org/doi/10.1145/363958.363994

7 – M. Ravanelli, T. Parcollet, P. Plantinga, A. Rouhe, S. Cornell, L. Lugosh, C. Subakan, N. Dawalatabad, A. Heba, J. Zhong, J.-C. Chou, S.-L. Yeh, S.-W. Fu, C.-F. Liao, E. Rastorgueva, F. Grondin, W. Aris, H. Na, Y. Gao, R. De Mori, Y. Bengio. SpeechBrain: A General-Purpose Speech Toolkit – https://arxiv.org/abs/2106.04624

8 – R. K. Kaliyar. A multi-layer bidirectional transformer encoder for pre-trained word embedding: a survey of BERT – https://ieeexplore.ieee.org/abstract/document/9058044

I - Annexe

Données complémentaires

a) Structure détaillée de Speechbrain wav2vec2

- wav2vec2
  - feature_extractor
    - 1×
      couche de convolution 1D, taille d'entrée **1**, taille de sortie 512, taille de noyau **10**
      layer_norm (taille 512, epsilon = $1e^{-5}$, elementwise_affine = True)
      Fonction d'activation: GELU
    - 4×
      couche de convolution 1D, tailles d'entrée et de sortie 512, taille de noyau **3**
      layer_norm (taille 512, epsilon = $1e^{-5}$, elementwise_affine = True)
      Fonction d'activation: GELU
    - 2×
      couche de convolution 1D, tailles d'entrée et de sortie 512, taille de noyau **2**
      layer_norm (taille 512, epsilon = $1e^{-5}$, elementwise_affine = True)
      Fonction d'activation: GELU
  - feature_projection
    - layer_norm (taille 512, epsilon = $1e^{-5}$, elementwise_affine = True)
      projection: Fonction linéaire (in_features = 512, out_features = 1024, bias = True)
      dropout (p = 0,1, inplace = False)
  - encoder: Wav2Vec2EncoderStableLayerNorm
    - pos_conv_embed: Wav2Vec2PositionalConvEmbedding
    - layer_norm (taille 1024, epsilon = $1e^{-5}$, elementwise_affine = True)
      dropout (p = 0,1, inplace = False)
    - 24× Wav2vec2EncoderLayerStableLayerNorm:
      - Wav2VecAttention
      - dropout (p = 0,1, inplace = False)
        layer_norm (taille 1024, epsilon = $1e^{-5}$, elementwise_affine = True)
      - Wav2Vec2FeedForward
- encoder
  - Fonction linéaire (in_features = out_features = 1024, bias = True)

BatchNorm1D (1024, epsilon = $1e^{-5}$, momentum = 0,1)
Fonction d'activation: LeakyReLU (negative_slope = 0,01)
Dropout (p = 0,15, inplace = False)

- Fonction linéaire (in_features = out_features = 1024, bias = True)
  BatchNorm1D (1024, epsilon = $1e^{-5}$, momentum = 0,1)
  Fonction d'activation: LeakyReLU (negative_slope = 0,01)
  Dropout (p = 0,15, inplace = False)

- Fonction linéaire (in_features = out_features = 1024, bias = True)
  BatchNorm1D (1024, epsilon = $1e^{-5}$, momentum = 0,1)
  Fonction d'activation: LeakyReLU (negative_slope = 0,01)

- ctc_lin
  - Fonction linéaire (in_features = 1024)
- Sortie

Fonction d'activation: Softmax

b) Mesures comparatives des différents modèles sur le corpus SPEECOMCO

- WER (avec arrondissement ± 0,0005):
    - Parole spontanée:

Patient n°	1	2	3	4	5	6	7	8	9	10	11	12	13
Sévérité du trouble	**6 ⅔**	2 ⅙	**8**	**9 ⅙**	5 ⅓	**6 ⅙**	3 ½	2 ⅓	**6 ⅓**	**7 ⅔**	0 ⅔	**6 ⅓**	**10**
Whisper Large	0,710	0,990	0,415	0,525	0,891	0,653	0,899	0,911	0,522	0,487	0,993	0,673	0,398
Speechbrain wav2vec2	0,715	0,876	0,412	0,479	0,732	0,712	0,852	0,881	0,593	0,534	0,966	0,710	0,265
Sb w2v PSI6 b8e4g4	0,776	0,896	0,462	0,569	0,763	0,791	0,897	0,913	0,689	0,519	0,959	0,823	0,335
Sb w2v PSI6 b8e8g4	0,735	0,913	0,433	0,523	0,787	0,751	0,902	0,925	0,643	0,468	0,959	0,744	0,310
Sb w2v PSI6 b8e12g4	0,737	0,894	0,438	0,503	0,756	0,736	0,895	0,908	0,636	0,460	0,959	0,733	0,299
Sb w2v PSI6 b8e16g2	0,728	0,878	0,427	0,501	0,736	0,734	0,875	0,901	0,619	0,453	0,959	0,731	0,277
Sb w2v PSI6 b8e20g2	0,726	0,878	0,424	0,496	0,738	0,731	0,861	0,903	0,621	0,446	0,959	0,731	0,278
Sb w2v PSI6 b12e20g2	0,722	0,885	0,418	0,501	0,747	0,720	0,873	0,909	0,616	0,442	0,959	0,720	0,271

Patient n°	14	15	16	17	18	19	20	21	22	23	24	25	26	27
Sévérité du trouble	**6 ⅔**	2 ⅙	5 ⅙	**6 ⅔**	**8 ⅔**	6	3 ⅓	**6 ⅙**	**9 ½**	**8 ⅚**	5 ⅔	0 ½	**8 ⅔**	**6 ⅚**
Whisper Large	0,535	0,922	0,615	0,461	0,383	0,958	0,939	0,717	0,458	0,770	0,617	0,949	0,363	0,725
Speechbrain wav2vec2	0,548	0,847	0,696	0,500	0,361	0,884	0,925	0,801	0,300	0,819	0,686	0,949	0,332	0,659
Sb w2v PSI6 b8e4g4	0,616	0,877	0,742	0,597	0,462	0,859	0,939	0,867	0,324	0,829	0,750	0,965	0,396	0,748
Sb w2v PSI6 b8e8g4	0,587	0,892	0,770	0,549	0,399	0,872	0,954	0,831	0,308	0,834	0,792	0,967	0,370	0,699
Sb w2v PSI6 b8e12g4	0,566	0,862	0,738	0,536	0,397	0,854	0,928	0,825	0,302	0,839	0,739	0,963	0,365	0,693
Sb w2v PSI6 b8e16g2	0,563	0,853	0,716	0,516	0,394	0,913	0,923	0,833	0,306	0,853	0,713	0,960	0,367	0,679
Sb w2v PSI6 b8e20g2	0,559	0,850	0,716	0,516	0,390	0,930	0,919	0,816	0,309	0,864	0,713	0,960	0,372	0,675
Sb w2v PSI6 b12e20g2	0,555	0,856	0,731	0,512	0,386	0,891	0,923	0,816	0,296	0,858	0,731	0,962	0,356	0,672

- Parole contrainte:

Patient n°	1	2	3	4	5	6	7	8	9	10	11	12	13
Sévérité du trouble	**6 ⅔**	2 ⅙	**8**	**9 ⅙**	5 ⅓	**6 ⅙**	3 ½	2 ⅓	**6 ⅓**	**7 ⅔**	0 ⅔	**6 ⅓**	**10**
Whisper Large	0,206	0,971	0,397	0,059	0,868	0,235	0,779	0,485	0,176	0,059	1,000	0,368	0,088
Speechbrain wav2vec2	0,382	0,882	0,529	0,221	0,618	0,603	0,735	0,750	0,397	0,324	0,985	0,618	0,221
Sb w2v PSI6 b8e4g4	0,500	0,926	0,515	0,221	0,691	0,721	0,809	0,809	0,426	0,338	0,985	0,735	0,176
Sb w2v PSI6 b8e8g4	0,456	0,897	0,529	0,206	0,721	0,603	0,765	0,779	0,441	0,324	0,985	0,647	0,176
Sb w2v PSI6 b8e12g4	0,426	0,897	0,515	0,221	0,721	0,588	0,779	0,779	0,441	0,353	1,000	0,647	0,176
Sb w2v PSI6 b8e16g2	0,441	0,868	0,544	0,221	0,662	0,618	0,750	0,765	0,426	0,338	1,000	0,662	0,206
Sb w2v PSI6 b8e20g2	0,397	0,897	0,515	0,235	0,676	0,588	0,765	0,765	0,412	0,324	1,000	0,676	0,221
Sb w2v PSI6 b12e20g2	0,412	0,868	0,529	0,250	0,691	0,559	0,765	0,779	0,382	0,324	1,000	0,676	0,176

Patient n°	14	15	16	17	18	19	20	21	22	23	24	25	26	27
Sévérité du trouble	**6** ⅔	2 ⅙	5 ⅙	**6** ⅔	**8** ⅔	6	3 ⅓	**6 ⅙**	**9** ½	**8** ⅚	5 ⅔	0 ½	**8** ⅔	**6 ⅚**
Whisper Large	0,147	0,853	0,265	0,103	0,103	0,294	1,132	0,206	0,074	0,074	0,235	0,971	0,103	0,235
Speechbrain wav2vec2	0,574	0,853	0,676	0,279	0,235	0,647	0,824	0,529	0,235	0,250	0,721	0,956	0,235	0,397
Sb w2v PSI6 b8e4g4	0,676	0,897	0,706	0,265	0,235	0,676	0,838	0,574	0,265	0,279	0,794	1,000	0,221	0,471
Sb w2v PSI6 b8e8g4	0,662	0,882	0,721	0,279	0,235	0,647	0,809	0,574	0,265	0,279	0,765	1,000	0,221	0,441
Sb w2v PSI6 b8e12g4	0,632	0,882	0,691	0,279	0,235	0,676	0,853	0,559	0,265	0,265	0,779	1,000	0,221	0,426
Sb w2v PSI6 b8e16g2	0,588	0,882	0,676	0,279	0,250	0,662	0,794	0,588	0,279	0,265	0,721	0,985	0,250	0,426
Sb w2v PSI6 b8e20g2	0,603	0,897	0,691	0,279	0,221	0,647	0,779	0,574	0,250	0,250	0,735	0,971	0,265	0,441
Sb w2v PSI6 b12e20g2	0,618	0,882	0,691	0,279	0,221	0,676	0,809	0,588	0,265	0,250	0,779	0,985	0,250	0,412

- CER (avec arrondissement ± 0,0005):
    - Parole spontanée:

Patient n°	1	2	3	4	5	6	7	8	9	10	11	12	13
Sévérité du trouble	**6** ⅔	2 ⅙	**8**	**9 ⅙**	5 ⅓	**6 ⅙**	3 ½	2 ⅓	**6** ⅓	**7** ⅔	0 ⅔	**6** ⅓	**10**
Whisper Large	0,461	0,654	0,258	0,318	0,629	0,453	0,644	0,670	0,340	0,368	0,766	0,442	0,283
Speechbrain wav2vec2	0,500	0,897	0,261	0,311	0,628	0,566	0,840	1,031	0,385	0,408	1,275	0,532	0,176
Sb w2v PSI6 b8e4g4	0,879	1,164	0,308	0,443	0,798	0,956	1,269	1,573	0,606	0,405	1,842	1,091	0,213
Sb w2v PSI6 b8e8g4	0,634	1,228	0,276	0,366	0,875	0,707	1,361	1,703	0,474	0,332	1,923	0,665	0,193
Sb w2v PSI6 b8e12g4	0,591	1,106	0,279	0,350	0,739	0,661	1,183	1,477	0,461	0,314	1,811	0,630	0,184
Sb w2v PSI6 b8e16g2	0,575	0,902	0,271	0,336	0,624	0,662	0,973	1,203	0,413	0,309	1,970	0,608	0,173
Sb w2v PSI6 b8e20g2	0,554	0,913	0,265	0,327	0,623	0,618	0,967	1,213	0,407	0,297	1,985	0,614	0,172
Sb w2v PSI6 b12e20g2	0,570	0,991	0,264	0,321	0,676	0,582	1,068	1,355	0,416	0,288	1,916	0,553	0,171

Patient n°	14	15	16	17	18	19	20	21	22	23	24	25	26	27
Sévérité du trouble	**6** ⅔	2 ⅙	5 ⅙	**6** ⅔	**8** ⅔	6	3 ⅓	**6 ⅙**	**9** ½	**8** ⅚	5 ⅔	0 ½	**8** ⅔	**6 ⅚**
Whisper Large	0,313	0,633	0,370	0,293	0,226	0,559	0,838	0,571	0,271	0,473	0,387	1,182	0,252	0,483
Speechbrain wav2vec2	0,370	0,728	0,467	0,323	0,215	0,617	0,832	0,786	0,175	0,511	0,500	1,378	0,198	0,510
Sb w2v PSI6 b8e4g4	0,509	1,132	0,592	0,473	0,322	0,739	1,248	1,286	0,196	0,587	0,695	2,139	0,250	0,824
Sb w2v PSI6 b8e8g4	0,430	1,206	0,651	0,388	0,256	0,698	1,415	0,933	0,184	0,564	0,782	2,334	0,228	0,657
Sb w2v PSI6 b8e12g4	0,397	1,056	0,561	0,369	0,249	0,745	1,136	0,918	0,181	0,538	0,642	2,142	0,217	0,621
Sb w2v PSI6 b8e16g2	0,388	0,856	0,485	0,337	0,235	0,653	0,864	0,961	0,181	0,533	0,524	1,896	0,219	0,607
Sb w2v PSI6 b8e20g2	0,387	0,859	0,483	0,337	0,231	0,641	0,864	0,855	0,180	0,534	0,521	2,004	0,218	0,571
Sb w2v PSI6 b12e20g2	0,372	0,958	0,518	0,334	0,228	0,683	0,973	0,828	0,176	0,525	0,584	2,092	0,207	0,544

- Parole contrainte:

Patient n°	1	2	3	4	5	6	7	8	9	10	11	12	13
Sévérité du trouble	**6 ⅔**	2 ⅙	**8**	**9 ⅙**	5 ⅓	**6 ⅙**	3 ½	2 ⅓	**6 ⅓**	**7 ⅔**	0 ⅔	**6 ⅓**	**10**
Whisper Large	0,128	0,865	0,277	0,064	0,485	0,146	0,603	0,261	0,115	0,074	19,5	0,216	0,044
Speechbrain wav2vec2	0,166	0,735	0,300	0,046	0,346	0,309	0,553	0,496	0,126	0,091	3,524	0,345	0,046
Sb w2v PSI6 b8e4g4	0,211	1,014	0,306	0,053	0,407	0,522	0,744	0,651	0,154	0,111	4,357	0,611	0,041
Sb w2v PSI6 b8e8g4	0,211	1,014	0,306	0,053	0,407	0,522	0,744	0,651	0,154	0,111	4,357	0,611	0,041
Sb w2v PSI6 b8e12g4	0,180	0,887	0,306	0,049	0,395	0,350	0,702	0,595	0,135	0,104	3,909	0,427	0,036
Sb w2v PSI6 b8e16g2	0,185	0,731	0,311	0,055	0,340	0,348	0,576	0,522	0,131	0,107	3,442	0,399	0,043
Sb w2v PSI6 b8e20g2	0,170	0,773	0,306	0,057	0,367	0,336	0,584	0,550	0,129	0,101	3,775	0,401	0,043
Sb w2v PSI6 b12e20g2	0,180	0,815	0,308	0,060	0,374	0,307	0,643	0,564	0,119	0,097	4,040	0,386	0,038

Patient n°	14	15	16	17	18	19	20	21	22	23	24	25	26	27
Sévérité du trouble	**6 ⅔**	2 ⅙	5 ⅙	**6 ⅔**	**8 ⅔**	6	3 ⅓	**6 ⅙**	**9 ½**	**8 ⅚**	5 ⅔	0 ½	**8 ⅔**	**6 ⅚**
Whisper Large	0,086	0,486	0,126	0,089	0,101	0,175	0,733	0,141	0,080	0,076	0,147	0,905	0,075	0,159
Speechbrain wav2vec2	0,396	0,738	0,310	0,080	0,068	0,399	0,755	0,291	0,058	0,078	0,302	2,470	0,054	0,218
Sb w2v PSI6 b8e4g4	0,607	1,095	0,390	0,108	0,083	0,467	1,125	0,399	0,073	0,085	0,385	4,515	0,052	0,289
Sb w2v PSI6 b8e8g4	0,607	1,095	0,390	0,108	0,083	0,467	1,125	0,399	0,073	0,085	0,385	4,515	0,052	0,289
Sb w2v PSI6 b8e12g4	0,429	1,014	0,391	0,097	0,074	0,469	1,039	0,332	0,076	0,084	0,364	4,612	0,055	0,248
Sb w2v PSI6 b8e16g2	0,389	0,771	0,331	0,093	0,083	0,405	0,779	0,343	0,075	0,082	0,304	2,794	0,060	0,254
Sb w2v PSI6 b8e20g2	0,391	0,837	0,340	0,088	0,074	0,404	0,779	0,317	0,067	0,082	0,324	2,990	0,060	0,245
Sb w2v PSI6 b12e20g2	0,399	0,963	0,395	0,082	0,077	0,438	0,849	0,319	0,072	0,084	0,359	3,447	0,057	0,222

c) Données statistiques

- WER (avec arrondissement ± 0,0005):
  - Parole spontanée:

Modèle	Moyenne			Médiane			Premier quartile	Troisième quartile
	Globale	Sév. -	Sév. +	Globale	Sév. -	Sév. +	Globale	Globale
Whisper Large	0,684	0,550	0,880	**0,673**	**0,5235**	0,922	0,5045	0,905
Speechbrain wav2vec2	**0,668**	**0,546**	**0,845**	0,71	0,541	**0,876**	0,517	0,8495
Sb w2v PSI6 b8e4g4	0,717	0,613	0,869	0,763	0,6065	0,896	0,583	0,872
Sb w2v PSI6 b8e8g4	0,701	0,574	0,885	0,751	0,568	0,902	0,536	0,882
Sb w2v PSI6 b8e12g4	0,687	0,567	0,863	0,737	0,551	0,894	0,5195	0,858
Sb w2v PSI6 b8e16g2	0,682	0,561	0,857	0,728	0,5395	0,878	0,5085	0,864
Sb w2v PSI6 b8e20g2	0,681	0,560	0,857	0,726	0,5375	0,878	0,506	0,8625
Sb w2v PSI6 b12e20g2	0,679	0,554	0,861	0,722	0,5335	0,885	0,5065	0,8655

- Parole contrainte:

Modèle	Moyenne			Médiane			Premier quartile	Troisième quartile
	Globale	Sév. -	Sév. +	Globale	Sév. -	Sév. +	Globale	Globale
Whisper Large	**0,388**	**0,165**	**0,714**	**0,235**	**0,125**	0,853	0,103	0,632
Speechbrain wav2vec2	0,544	0,377	0,786	0,574	0,353	**0,75**	0,3015	0,728
Sb w2v PSI6 b8e4g4	0,583	0,414	0,830	0,676	0,382	0,809	0,3085	0,8015
Sb w2v PSI6 b8e8g4	0,567	0,396	0,816	0,603	0,3825	0,779	0,3015	0,765
Sb w2v PSI6 b8e12g4	0,567	0,391	0,824	0,588	0,3895	0,779	0,316	0,779
Sb w2v PSI6 b8e16g2	0,561	0,399	0,797	0,588	0,382	0,765	0,3085	0,7355
Sb w2v PSI6 b8e20g2	0,558	0,391	0,802	0,588	0,3605	0,765	0,3015	0,75
Sb w2v PSI6 b12e20g2	0,560	0,387	0,811	0,588	0,353	0,779	0,3015	0,772

- CER (avec arrondissement ± 0,0005):
  - Parole spontanée:

Modèle	Moyenne			Médiane			Premier quartile	Troisième quartile
	Globale	Sév. -	Sév. +	Globale	Sév. -	Sév. +	Globale	Globale
Whisper Large	**0,487**	**0,363**	**0,667**	**0,453**	**0,329**	**0,644**	0,3155	0,631
Speechbrain wav2vec2	0,571	0,389	0,836	0,51	0,3775	0,832	0,3465	0,757
Sb w2v PSI6 b8e4g4	0,835	0,584	1,199	0,739	0,491	1,164	0,458	1,148
Sb w2v PSI6 b8e8g4	0,795	0,455	1,289	0,657	0,409	1,228	0,377	1,0695
Sb w2v PSI6 b8e12g4	0,724	0,435	1,145	0,621	0,383	1,106	0,3595	0,987
Sb w2v PSI6 b8e16g2	0,658	0,426	0,996	0,575	0,3625	0,864	0,3365	0,86
Sb w2v PSI6 b8e20g2	0,653	0,410	1,006	0,554	0,362	0,864	0,332	0,857
Sb w2v PSI6 b12e20g2	0,674	0,399	1,074	0,553	0,353	0,973	0,3275	0,893

- Parole contrainte:

Modèle	Moyenne			Médiane			Premier quartile	Troisième quartile
	Globale	Sév. -	Sév. +	Globale	Sév. -	Sév. +	Globale	Globale
Whisper Large	0,969	**0,117**	2.208	**0,146**	**0,095**	**0,486**	0,0875	0,381
Speechbrain wav2vec2	**0,493**	0,167	**0,966**	0,302	0,1085	0,553	0,0855	0,4475
Sb w2v PSI6 b8e4g4	0,698	0,232	1,377	0,39	0,1325	0,744	0,1095	0,631
Sb w2v PSI6 b8e8g4	0,603	0,192	1,201	0,39	0,1325	0,744	0,1095	0,631
Sb w2v PSI6 b8e12g4	0,643	0,186	1,307	0,35	0,1195	0,702	0,1005	0,532
Sb w2v PSI6 b8e16g2	0,517	0,185	0,999	0,331	0,119	0,576	0,1	0,4635
Sb w2v PSI6 b8e20g2	0,540	0,179	1,066	0,324	0,115	0,584	0,0945	0,477
Sb w2v PSI6 b12e20g2	0,581	0,176	1,172	0,319	0,108	0,643	0,0905	0,501

d) Tests statistiques

Sont indiqués uniquement les scores $p < 0,05$ (avec arrondissement ± 0,0005).

- WER parole spontanée: néant
- WER parole contrainte:
  - Données globales:
    - entre Whisper Large et Speechbrain wav2vec2: $p = 0,019$
    - entre Whisper Large et Speechbrain PSI 4E: $p = 0,012$
    - entre Whisper Large et Speechbrain PSI 8E: $p = 0,015$
    - entre Whisper Large et Speechbrain PSI 12E: $p = 0,013$
    - entre Whisper Large et Speechbrain PSI 16E: $p = 0,011$
    - entre Whisper Large et Speechbrain PSI 20E: $p = 0,013$
    - entre Whisper Large et Speechbrain PSI 20E12B: $p = 0,013$
  - Patients peu atteints: néant
  - Patients très atteints:
    - entre Whisper Large et Speechbrain wav2vec2: $p < 0,001$
    - entre Whisper Large et Speechbrain PSI 4E: $p < 0,001$
    - entre Whisper Large et Speechbrain PSI 8E: $p < 0,001$
    - entre Whisper Large et Speechbrain PSI 12E: $p < 0,001$
    - entre Whisper Large et Speechbrain PSI 16E: $p < 0,0001$
    - entre Whisper Large et Speechbrain PSI 20E: $p < 0,0001$
    - entre Whisper Large et Speechbrain PSI 20E12B: $p < 0,0001$
- CER parole spontanée:
  - Données globales:
    - entre Whisper Large et Speechbrain PSI 4E: $p = 0,008$
    - entre Whisper Large et Speechbrain PSI 8E: $p = 0,059$
  - Patients peu atteints:
    - entre Whisper Large et Speechbrain PSI 4E: $p = 0,006$

        - entre Whisper Large et Speechbrain PSI 8E: p = 0,001
        - entre Speechbrain wav2vec2 et Speechbrain PSI 8E: p = 0,041
        - entre Whisper Large et Speechbrain PSI 12E: p = 0,015
        - entre Whisper Large et Speechbrain PSI 20E12B: p = 0,030
    - Patients très atteints:
        - entre Whisper Large et Speechbrain PSI 4E: p = 0,070
- CER parole contrainte: néant